

Unsupervised Learning - Ryan



Soal 1

1. Lakukan EDA pada dataset untuk mendapatkan pemahaman umum mengenai data dan memandu proses feature engineering (20 poin)

Langkah-langkah:

- Pastikan setiap kolom dataset memiliki tipe data yang tepat, tidak ada data kosong, bebas dari duplikat, dan berada di *range* value yang tepat
- Keluarkan statistik kolom baik numerik maupun kategorikal, cari bentuk distribusi setiap kolom (numerik), dan jumlah baris untuk setiap *unique* value (kategorikal)
- Cari tahu apakah ada kolom-kolom yang berkorelasi kuat satu sama lain

Untuk mempermudah kamu, yuk lihat resource di bawah ini:

- Topic Machine Learning Preparation - EDA

Soal 1a (Descriptive Analysis) (Method)

- Data Numerikal:
 - Dikarenakan pandas sudah secara otomatis melakukan konversi data yang bersifat *object* namun berada di kolom int/float menjadi 'NaN', maka hanya perlu pengecekan nilai null di dalam kolom-kolom numerikal tersebut
- Data Non-Numerikal:
 - Dikarenakan banyak nya variasi di kolom ini, maka perlakuannya akan berbeda per kolom.
- Data Temporal/Tanggal:
 - Kolom di konversi ke tipe data tanggal, dengan begitu jika ada nilai yang tidak sesuai, maka secara otomatis data yang tidak sesuai akan berubah menjadi nilai 'NaT' yang bisa di cek dengan fungsi `isna()`.

Soal 1a (Descriptive Analysis) (Conclusion)

- **FIRST_FLIGHT_DATE:**
 - Dari pengecekan, ditemukan 3 baris yang memiliki nilai yang jauh diluar rata-rata
- **GENDER:**
 - Kolom ditemukan memiliki 3 baris dimana nilai nya bukan 'Female' maupun 'Male'.
- **WORK_CITY:**
 - Dikarenakan sifat nilai di kolom ini yang sangat bervariasi (dengan total 3234 nilai yang DISTINCT), maka tidak mungkin dilakukan pengecekan apakah semua nilai di kolom ini benar-benar memang nama dari sebuah kota. Dengan begitu ditentukan bahwa dilakukan pengecekan jika nilai di kolom hanya ada angka ataupun karakter spesial ataupun kosong sama sekali, maka dianggap tidak benar. Dari pengecekan ditemukan ada 787 baris yang memiliki nilai kolom 'WORK_CITY' yang tidak benar & 2269 baris yang memiliki nilai null.
- **WORK_PROVINCE:**
 - Dikarenakan sifat nilai di kolom ini yang sangat bervariasi (dengan total 1165 nilai yang DISTINCT), maka tidak mungkin dilakukan pengecekan apakah semua nilai di kolom ini benar-benar memang nama dari sebuah provinsi. Dengan begitu ditentukan bahwa dilakukan pengecekan jika nilai di kolom hanya ada angka ataupun karakter spesial ataupun kosong sama sekali, maka dianggap tidak benar. Dari pengecekan ditemukan ada 1283 baris yang memiliki nilai kolom 'WORK_PROVINCE' yang tidak benar & 3248 baris yang memiliki nilai null.
- **WORK_COUNTRY:**
 - Dikarenakan nilai-nilai di kolom ini memiliki karakteristik akan sama dengan 2 karakter, ataupun berkarakter mandarin. Maka hanya akan dilakukan pengecekan untuk nilai null saja. Dari pengecekan ditemukan ada 26 baris yang memiliki nilai null.
- **AGE:**
 - Dikarenakan kolom ini sudah termasuk tipe data numerik, maka sudah akan terjamin bahwa tidak akan ada nilai berupa string, maka akan dilakukan pengecekan nilai NaN ataupun null. Dari hasil pengecekan ditemukan bahwa ada 420 baris yang memiliki nilai 'AGE' null/tidak benar.
- **LOAD_TIME:**
 - Ditemukan bahwa kolom ini memiliki nilai yang sama untuk semua baris. Maka ditentukan bahwa kolom ini akan dihapus dari dataset, dikarenakan memiliki variasi yang terlalu sedikit dan tidak akan bisa dipakai untuk segmentasi.
- **SUM_YR_1:**
 - Ditemukan bahwa kolom ini mempunyai 551 baris dengan nilai null.
- **SUM_YR_2:**
 - Ditemukan bahwa kolom ini mempunyai 138 baris dengan nilai null.
- **LAST_FLIGHT_DATE:**
 - Ditemukan bahwa kolom ini memiliki 421 baris dimana nilai kolom ini *invalid* atau null.

Untuk mempersingkat, kolom yang tidak bermasalah tidak akan di sebut di *slide* ini.

Soal 1b (Numeric Analysis)


	MEMBER_NO	FFP_TIER	AGE	FLIGHT_COUNT	BP_SUM	SUM_YR_1	SUM_YR_2	SEG_KM_SUM	LAST_TO_END	AVG_INTERVAL	MAX_INTERVAL	EXCHANGE_COUNT	avg_discount	Points_Sum	Point_NotFlight
count	62988.000000	62988.000000	62568.000000	62988.000000	62988.000000	62437.000000	62850.000000	62988.000000	62988.000000	62988.000000	62988.000000	62988.000000	62988.000000	62988.0000	62988.000000
mean	31494.500000	4.102162	42.476346	11.839414	10925.081254	5355.376064	5604.026014	17123.878691	176.120102	67.749788	166.033895	0.319775	0.721558	12545.7771	2.728155
std	18183.213715	0.373856	9.885915	14.049471	16339.486151	8109.450147	8703.364247	20960.844623	183.822223	77.517866	123.397180	1.136004	0.185427	20507.8167	7.364164
min	1.000000	4.000000	6.000000	2.000000	0.000000	0.000000	0.000000	368.000000	1.000000	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000
25%	15747.750000	4.000000	35.000000	3.000000	2518.000000	1003.000000	780.000000	4747.000000	29.000000	23.370370	79.000000	0.000000	0.611997	2775.0000	0.000000
50%	31494.500000	4.000000	41.000000	7.000000	5700.000000	2800.000000	2773.000000	9994.000000	108.000000	44.666667	143.000000	0.000000	0.711856	6328.5000	0.000000
75%	47241.250000	4.000000	48.000000	15.000000	12831.000000	6574.000000	6845.750000	21271.250000	268.000000	82.000000	228.000000	0.000000	0.809476	14302.5000	1.000000
max	62988.000000	6.000000	110.000000	213.000000	505308.000000	239560.000000	234188.000000	580717.000000	731.000000	728.000000	728.000000	46.000000	1.500000	985572.0000	140.000000

Soal 1b (Categorical Analysis)

	GENDER	WORK_CITY	WORK_PROVINCE	WORK_COUNTRY	LOAD_TIME
count	62985	60719	59740	62962	62988
unique	2	3234	1165	118	1
top	Male	guangzhou	guangdong	CN	3/31/2014
freq	48134	9386	17509	57748	62988

Soal 1b (Univariate Analysis) (FFP_DATE)

Distribution of FFP_DATE




Soal 1b (Univariate Analysis) (FFP_DATE) (CONCLUSION)

Data menunjukkan bahwa distribusi nilai di kolom ini tergolong *positively skewed* dimana jumlah pelanggan yang mengikuti program *frequent flyer* mengalami kenaikan linear. Namun terlihat ada penurunan drastis di awal tahun 2009, tetapi angka *frequent flyer* secara cepat kembali ke angka semula, dan ada kenaikan drastis juga di tahun 2012.

Dikarenakan distribusi yang *skewed* namun tetap bervariasi, dan juga data temporal, maka fitur ini tetap bisa dipakai untuk model *clustering*.


Soal 1b (Univariate Analysis) (FIRST_FLIGHT_DATE)



Soal 1b (Univariate Analysis) (FIRST_FLIGHT_DATE) (CONCLUSION)

Data menunjukkan bahwa ada nya nilai *outlier* di data sehingga visualisasi data terlihat lebih *skewed* dari distribusi asli nya.

Soal 1b (Univariate Analysis) (FIRST_FLIGHT_DATE) (CLEAN)




Soal 1b (Univariate Analysis) (FIRST_FLIGHT_DATE) (CLEAN) (CONCLUSION)

Data (yang sudah dihapus *outlier* nya) menunjukkan bahwa distribusi nilai di kolom ini tergolong *positively skewed* dimana jumlah pelanggan yang pertama kali terbang bersama perusahaan mengalami kenaikan linear. Namun terlihat ada penurunan drastis di awal tahun 2009, tetapi angka *frequent flyer* secara cepat kembali ke angka semula, dan ada kenaikan drastis juga di tahun 2012 sampai dengan tahun 2013. Lalu ada penurunan kedua drastis setelah tahun 2013 sampai 2014.

Dikarenakan distribusi yang *skewed* namun tetap bervariasi, dan juga data temporal, maka fitur ini tetap bisa dipakai untuk model *clustering*.

Soal 1b (Univariate Analysis) (GENDER)

Distribution of GENDER




Soal 1b (Univariate Analysis) (GENDER) (CONCLUSION)

Dari data diketahui bahwa mayoritas besar pelanggan adalah pria.

Untuk kolom ini hanya ada 3 baris yang mempunyai nilai null, maka **data cleaning** akan dilakukan dengan cara penghapusan baris (jika fitur dipilih untuk modeling).

Selain itu, data juga akan di terapi *label encoding* dikarenakan jumlah kategori yang hanya 2.

Soal 1b (Univariate Analysis) (FFP_TIER)




Soal 1b (Univariate Analysis) (FFP_TIER) (CONCLUSION)

Data menunjukkan bahwa nilai dari fitur ini didominasi oleh 1 kategori dimana mayoritas (>90%) berada di golongan *Frequent Flyer* paling rendah,

Kolom ini terlihat tidak mempunyai nilai null, dan tidak ada nilai yang janggal, maka tidak perlu dilakukan nya **data cleaning**.

Soal 1b (Univariate Analysis) (WORK_CITY)




Soal 1b (Univariate Analysis) (WORK_CITY) (CONCLUSION)

Data menunjukkan bahwa distribusi data tergolong *extremely positively skewed* dimana pelanggan terlihat terkonsentrasi hanya di beberapa kota. Sekitar 90% berada di 10 kota saja.

Terlihat juga bahwa nilai di kolom ini tidak mempunyai standar sehingga format tiap nilai bisa berbeda, dan bisa juga duplikat.

Selain itu terlihat data sampah dimana ada baris dengan nilai yang isinya hanya karakter spesial atau angka saja.

Soal 1b (Univariate Analysis) (WORK_PROVINCE)




Soal 1b (Univariate Analysis) (WORK_PROVINCE) (CONCLUSION)

Data menunjukkan bahwa distribusi data tergolong *extremely positively skewed* dimana pelanggan terlihat terkonsentrasi hanya di beberapa provinsi.

Terlihat juga bahwa nilai di kolom ini tidak mempunyai standar sehingga format tiap nilai bisa berbeda, dan bisa juga duplikat.

Selain itu terlihat data sampah dimana ada baris dengan nilai yang isi nya hanya karakter spesial atau angka saja.

Soal 1b (Univariate Analysis) (WORK_COUNTRY)




Soal 1b (Univariate Analysis) (WORK_COUNTRY) (CONCLUSION)

Data menunjukkan bahwa distribusi data tergolong *extremely skewed* dimana 90% pelanggan berada di 1 negara saja.

Kolom ini nilai nya sudah terlihat *standardized* dimana format tiap nilai sudah sama.


Soal 1b (Univariate Analysis) (AGE)



Soal 1b (Univariate Analysis) (AGE) (CONCLUSION)

Data menunjukkan distribusi normal dengan mayoritas nilai berada di sekitar umur 40.


Soal 1b (Univariate Analysis) (LOAD_TIME)



Soal 1b (Univariate Analysis) (LOAD_TIME) (CONCLUSION)

Data menunjukkan bahwa kolom ini mempunyai variasi 0, dimana nilai nya sudah pasti sama untuk semua kolom. Dengan begitu, fitur ini tidak akan berguna untuk tujuan *clustering*.


Soal 1b (Univariate Analysis) (FLIGHT_COUNT)



Soal 1b (Univariate Analysis) (FLIGHT_COUNT) (CONCLUSION)

Data menunjukkan bahwa kolom ini tergolong *positively skewed* mayoritas pelanggan hanya pernah terbang 1 atau 2 kali, lalu secara eksponensial turun ke 15, lalu secara linear turun ke sekitar 200.


Soal 1b (Univariate Analysis) (BP_SUM)



Soal 1b (Univariate Analysis) (BP_SUM) (CONCLUSION)

Data menunjukkan bahwa kolom ini tergolong *positively skewed* dimana mayoritas nilai nya ada di 20000, namun ada *outlier* sampai nilai 510000.


Soal 1b (Univariate Analysis) (SEG_KM_SUM)



Soal 1b (Univariate Analysis) (SEG_KM_SUM) (CONCLUSION)

Data menunjukkan bahwa kolom ini tergolong *positively skewed* dimana mayoritas nilai nya ada di 50000, namun ada *outlier* sampai nilai 590000.


Soal 1b (Univariate Analysis) (LAST_FLIGHT_DATE)



Soal 1b (Univariate Analysis) (LAST_FLIGHT_DATE) (CONCLUSION)

Data menunjukkan bahwa kolom ini tergolong *negatively skewed* dimana mayoritas nilai nya ada April 2014, namun ada *outlier* sampai nilai April 2012.


Soal 1b (Univariate Analysis) (LAST_TO_END)



Soal 1b (Univariate Analysis) (LAST_TO_END) (CONCLUSION)

Data menunjukkan bahwa kolom ini tergolong *positively skewed* dimana mayoritas nilai nya ada di sekitar 0, lalu secara linear berkurang sampai 720.


Soal 1b (Univariate Analysis) (AVG_INTERVAL)



Soal 1b (Univariate Analysis) (AVG_INTERVAL) (CONCLUSION)

Data menunjukkan bahwa kolom ini tergolong *positively skewed* dimana mayoritas nilai nya ada di sekitar 0, lalu secara linear berkurang sampai 720.


Soal 1b (Univariate Analysis) (MAX_INTERVAL)



Soal 1b (Univariate Analysis) (MAX_INTERVAL) (CONCLUSION)

Data menunjukkan bahwa kolom ini tergolong *positively skewed* dimana mayoritas nilai nya ada di sekitar 0, lalu ada penurunan drastis ke nilai 30. Namun secara perlahan ada kenaikan sampai 120, dan kembali ada penurunan linear sampai 720.


Soal 1b (Univariate Analysis) (EXCHANGE_COUNT)



Soal 1b (Univariate Analysis) (EXCHANGE_COUNT) (CONCLUSION)

Data menunjukkan bahwa kolom ini tergolong *positively skewed* dimana mayoritas nilai nya ada di sekitar 0, lalu ada penurunan drastis di nilai 1, lalu frekuensi mendekati 0 sampai nilai 46.


Soal 1b (Univariate Analysis) (avg_discount)



Soal 1b (Univariate Analysis) (avg_discount) (CONCLUSION)

Data menunjukkan bahwa distribusi kolom ini tergolong normal dimana mayoritas nilai nya ada di sekitar 0.8, lalu ada penurunan namun ada kenaikan drastis di nilai 1.0, lalu kembali ada penurunan drastis diatas 1.0


Soal 1b (Univariate Analysis) (Points_Sum)



Soal 1b (Univariate Analysis) (Points_Sum) (CONCLUSION)

Data menunjukkan bahwa kolom ini tergolong *positively skewed* dimana mayoritas nilai nya ada di sekitar 0, lalu ada penurunan drastis dan frekuensi mendekati 0 sampai nilai 0.95.


Soal 1b (Univariate Analysis) (Point_NotFlight)



Soal 1b (Univariate Analysis) (Point_NotFlight) (CONCLUSION)

Data menunjukkan bahwa kolom ini tergolong *positively skewed* dimana mayoritas nilai nya ada di sekitar 0, lalu ada penurunan drastis dan frekuensi mendekati 0 sampai nilai 140.

Soal 1c (Multivariate Analysis) (Numerical Data)




Soal 1c (Multivariate Analysis) (Numerical Data)

Data menunjukkan bahwa FFP_DATE dan FIRST_FLIGHT_DATE sangat berkorelasi, dimana artinya lebih *early* pelanggan terbang, maka lebih *early* juga pelanggan masuk ke program *Frequent Flyer*.

Lalu ada korelasi yang kuat untuk kolom FLIGHT_COUNT, BP_SUM, SUM_YR_1, SUM_YR_2, SEG_KM_SUM yang menggambarkan bahwa semakin sering pelanggan terbang, maka semakin banyak juga KM dan uang yang dikeluarkan.

Soal 1c (Multivariate Analysis) (Categorical Data)



Soal 1c (Multivariate Analysis) (Categorical Data)

Data menunjukkan bahwa WORK_COUNTRY, WORK_PROVINCE, dan WORK_COUNTRY berkorelasi dengan kuat.

Soal 2

2. Pilih fitur-fitur yang menurut teman-teman masuk akal secara bisnis untuk digunakan sebagai fitur clustering. Lakukan feature engineering! (20 poin)

Langkah-langkah:

- Dari sekian banyak kolom yang ada, tentukan 3-6 fitur untuk digunakan sebagai fitur *clustering*. **Tulis alasan teman-teman memilih fitur tersebut.**
- Lakukan preprocessing dan feature engineering** (apabila fitur yang teman-teman pilih merupakan fitur baru yang dihasilkan dari fitur-fitur yang sudah ada).

Untuk mempermudah kamu, yuk lihat resource di bawah ini:

- Topic Machine Learning Preparation - Feature Engineering

Soal 2 (Feature Engineering)

- **FLIGHT_FREQ:**

- Fitur ini dibuat untuk menghitung apakah seorang pelanggan sering terbang atau tidak.
Fitur ini dibuat dari komponen $\text{FLIGHT_COUNT} / (\text{LAST_FLIGHT_DATE} - \text{FIRST_FLIGHT_DATE})$

- **AVG_SEG_KM:**

- Fitur ini dibuat untuk menghitung apakah seorang pelanggan termasuk pelanggan yang meminati penerbangan jarak pendek atau jarak jauh.
Fitur ini dibuat dari komponen $\text{SEG_KM_SUM} / \text{FLIGHT_COUNT}$

- **LAST_TO_END:**

- Fitur ini dipakai untuk menghitung seberapa terkini seorang pelanggan melakukan transaksi.

- **SPEND_PER_FLIGHT:**

- Fitur ini dibuat untuk menghitung apakah seorang pelanggan lebih meminati penerbangan yang premium atau ekonomis.
Fitur ini dibuat dari komponen $(\text{SUM_YR_1} + \text{SUM_YR_2}) / \text{FLIGHT_COUNT}$

- **avg_discount:**

- Fitur ini dipakai untuk menghitung apakah seorang pelanggan mementingkan potongan harga saat melakukan pembelian tiket penerbangan.

Soal 3

3. Lakukan clustering K-means! Temukan jumlah cluster yang menurut teman-teman optimal dan evaluasi cluster yang dihasilkan dengan visualisasi dan silhouette score (30 poin)


Langkah-langkah:

- Temukan jumlah cluster yang optimal dengan menggunakan elbow method
- Lakukan clustering menggunakan K-means**
- Evaluasi cluster yang dihasilkan dengan menggunakan visualisasi, gunakan PCA apabila diperlukan

Untuk mempermudah kamu, yuk lihat resource di bawah ini:

- Topic Unsupervised Learning - Clustering bagian KMeans dan Evaluasi


Soal 3 (Elbow Method)




Soal 3 (Elbow Method) (CONCLUSION)

Setelah dilakukan *Elbow Method* dengan semua data numerikal yang sudah di *normalized* dan *standardized* (kecuali AGE), ditemukan bahwa clustering paling optimal berada di 6 *clusters*.

Soal 3 (Clustering)



Soal 3 (Cluster Evaluation)



Soal 4

4. Interpretasi cluster yang dihasilkan secara bisnis dan berikan rekomendasi yang sesuai dengan cluster yang dihasilkan (30 poin)

Langkah-langkah:

- Tempelkan kembali label yang dihasilkan ke dataframe asal, dan keluarkan statistik fitur dari setiap cluster
- Deskripsikan secara kontekstual customer seperti apa yang ada di masing-masing cluster**
- Berdasarkan cluster tersebut, berikan 1-2 rekomendasi bisnis

Untuk mempermudah kamu, yuk lihat resource di bawah ini:

- Topic Unsupervised Learning - Clustering

Soal 4 (Clustering) (CONCLUSION)

- Cluster 0:
 - Pelanggan rata-rata yang tidak mempunyai sinyal negatif maupun positif.
- Cluster 1:
 - Pelanggan yang lebih senior dan lebih condong terbang dengan jarak yang jauh dan juga biasanya menghabiskan uang lebih banyak per penerbangan.
- Cluster 2:
 - Pelanggan rata-rata yang lebih responsif terhadap diskon.
- Cluster 3:
 - Pelanggan yang lebih sering terbang.
- Cluster 4:
 - Pelanggan yang memilih untuk tidak banyak *spending*.
- Cluster 5:
 - Pelanggan yang jarang terbang dan jarang untuk melakukan *spending* lebih.

Soal 4 (Business Recommendation)

- Cluster 0:
 - Tidak ada perlakuan khusus dikarenakan pelanggan di segment ini tidak responsif terhadap promosi atau diskon.
- Cluster 1:
 - Menawarkan *upgrade* yang condong terhadap kenyamanan seperti *upgrade* kelas penerbangan atau bangku yang lebih dekat dengan toilet.
- Cluster 2:
 - Menawarkan bundling ekonomis yang sudah termasuk penerbangan, bagasi, dan bangku yang lebih luas ruangan kaki nya. Juga menawarkan insentif agar pelanggan tetap loyal dan sering terbang.
- Cluster 3:
 - Menawarkan insentif agar pelanggan tetap loyal dan sering terbang.
- Cluster 4:
 - Tidak ada perlakuan khusus karena pelanggan di cluster ini termasuk *low-profit*.
- Cluster 5:
 - Melakukan edukasi benefit saat menjadi pelanggan yang loyal. Dan juga memberi insentif saat terbang pertama kali dengan penerbangan ini.

Terima Kasih!